Caso 4: Predicting Customer Churn

Juan Esteban Daza Forero

Sofia Acuña Cifuentes

Mariana Andrea Hernández Pinto

Docente:
Juan Nicolas Velásquez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

28/04/2026

Introducción

QWE INC. es una empresa que ofrece servicios digitales por suscripción a pequeñas y medianas empresas. Hasta 2012, gestionaba la deserción de clientes de forma reactiva, ofreciendo descuentos o beneficios al momento de la cancelación, lo que resultaba costoso e ineficiente. Ante esto, se planteó desarrollar un modelo predictivo que permitiera anticipar qué clientes tienen mayor probabilidad de abandonar el servicio en el corto plazo y así implementar estrategias más efectivas. Para ello, se cuenta con una base de datos de 6,347 clientes con información sobre antigüedad, satisfacción (CHI), uso del servicio y soporte, donde la variable de interés es la deserción (churn), la cual presenta un bajo porcentaje (~5%), implicando un problema de datos desbalanceados.

Análisis de Deserción de Clientes - QWE INC.

Tabla 1. Estadísticas Descriptivas

Variable	N	Media	Mediana	Desv. Estándar	Mínimo	Máximo
Edad del cliente (meses)	6,347	13.90	11	11.16	0	67
CHI Score (mes 0)	6,347	87.32	87	66.28	0	298
Cambio CHI Score	6,347	5.06	0	30.83	-125	208
Casos de soporte (mes 0)	6,347	0.71	0	1.72	0	32
Cambio casos de soporte	6,347	-0.01	0	1.87	-29	31
Cambio en login	6,347	15.73	2	42.12	-293	865
Cambio en vistas	6,347	96.31	0	3,152.41	-28,322	230,414
Cambio días sin login	6,347	1.76	0	17.97	-648	61

La Tabla 1 presenta las estadísticas descriptivas de las variables continuas incluidas en el modelo con 6,347 observaciones sin valores faltantes. Ahora, la **edad promedio del cliente es de 13.9 meses**, lo que indica una base de usuarios relativamente reciente, con alta dispersión (DE = 11.16). El **CHI Score promedio es elevado (87.32),** con una alta variabilidad (SD = 153.52), lo que sugiere diferencias importantes en la salud percibida de la relación con el cliente. Por otro lado, los **casos de soporte son bajos en promedio (0.71),** pero con valores extremos que podrían estar asociados a clientes con problemas específicos. Las variables de cambio (login, vistas y días sin login) presentan **alta variabilidad y presencia de valores extremos**, especialmente en vistas, lo que indica comportamientos diferentes en el uso de la plataforma. De esta forma, los resultados sugieren una base de clientes diversa, donde algunos usuarios muestran alta actividad mientras otros presentan patrones de uso más limitados, lo cual puede ser relevante para explicar la deserción.

Ahora bien, para resolver el caso, se decidió utilizar un modelo Logit (Tabla 2), debido a que la variable dependiente "churn" es binaria (0= no deserta, 1= deserta), por lo que la regresión lineal normal no es la más apropiada. Con el modelo logia estima la probabilidad de que un cliente abandone la empresa en función de sus características.

Tabla 2. Modelo Logit - Variable Dependiente: Churn

Variable	Coeficiente	Error Estándar	Estadístico Z	p-value	Sig.
Intercepto	-2.7608	0.1059	-26.07	0.0000	***
Edad del cliente (meses)	0.0126	0.0054	2.35	0.0190	*
CHI Score (mes 0)	-0.0046	0.0012	-3.87	0.0001	***
Cambio CHI Score	-0.0104	0.0024	-4.32	0.0000	***
Casos de soporte (mes 0)	-0.1369	0.0718	-1.91	0.0563	.
Cambio casos de soporte	0.1329	0.0640	2.08	0.0379	*
Cambio en login	0.0002	0.0021	0.12	0.9056	
Cambio en vistas	-0.0001	0.0000	-2.73	0.0063	**
Cambio días sin login	0.0172	0.0043	4.02	0.0001	***

Nota: *** p<0.001 ** p<0.01 * p<0.05 . p<0.1
McFadden R^2 = 0.0439387489527788 | N = 6347

El McFadden R^2 = 0.0439387489527788 indica que el modelo explica aproximadamente el 4.4% de la variación en la deserción.

Es importante mencionar que el modelo se estimó sobre los 6.347 registros disponibles e incorporo ocho variables independientes que capturan distintas dimensiones del comportamiento y perfil del cliente: antigüedad en la empresa, nivel de satisfacción que se mide por medio del "Customer Health Index" (CHI), historial de soporte técnico y grado de interacción con la plataforma los resultados obtenidos se observan en la Tabla 2.

De acuerdo a los resultados obtenidos (Tabla 2), de las ocho variables que se incluyeron en el modelo, seis resultaron estadísticamente significativas al 5% o Superior. Las variables que obtuvieron un mayor nivel de significancia (p-value < 0.001) son el CHI escore, el cambio en el CHI escoré y el cambio en los días sin inicio de sesión, lo cual indica que estas variables son las más indicadas para identificar clientes en riesgo de deserción. El cambio en el número de visitas resulto ser significativo al 1% (p-value < 0.01), mientras que la edad del cliente y el cambio en los casos de soporte alcanzaron el umbral del 5%.

Los signos de los coeficientes son acordes teniendo en cuenta la lógica de negocio y permiten sacar conclusiones accionables. El coeficiente del CHI Score inicial (-0.0046) y el de su cambio (-0.0104) son negativos y significativos, lo que indica que los clientes que tienen una mayor satisfacción y aquellos que su satisfacción mejora con el tiempo tienen una más alta probabilidad de abandonar la empresa. Esto respalda el uso del CHI Score como indicador temprano de riesgo: una caída en este índice debe activar las alertas de retención de forma proactiva.

El coeficiente asociado al cambio de los días sin login (0.0172) es altamente significativo, lo que confirma que la inactividad en la plataforma resulta ser una señal de desvinculación. Al igual que el incremento en los casos de soporte (0.1329) aumenta la

probabilidad de deserción, lo cual sugiere que la acumulación de problemas técnicos no resueltos degrada la experiencia del cliente por lo que aumenta la posibilidad de abandonar el servicio.

Al realizar el ajuste del R^2 de McFadden, es una medida análoga adaptada para este tipo de modelo. El valor obtenido fue de 0.044, lo cual se puede considerar modesto. Sin embargo, cuando se trata del modelo logit aplicados a datos de comportamiento humano los valores entre 0.02 y 0.10 son aceptables y típicos. Por lo que en este modelo que cuenta con seis variables significativas representa un modelo estadísticamente valido y con alta capacidad predictiva real.

Los resultados obtenidos en este modelo permiten que se identifiquen tres señales de alerta temprana que la empresa debería monitorear de forma sistemática para anticipar la deserción de clientes. Lo primero es que una caída en el CHI Score que resulto ser el mejor predictor. Segundo, el aumento en los días sin login son una señal de abandono del servicio. Tercero el incremento en los tickets de soporte abiertos indica un deterioro en la experiencia lo que requiere intervención.

Así pues, este modelo da una base sólida para priorizar la retención, para que los equipos encargados dirijan recursos a aquellos clientes que tienen mayor probabilidad de deserción antes de que la decisión de abandono sea definitiva.

Gráfica 1. Matriz de Confusión

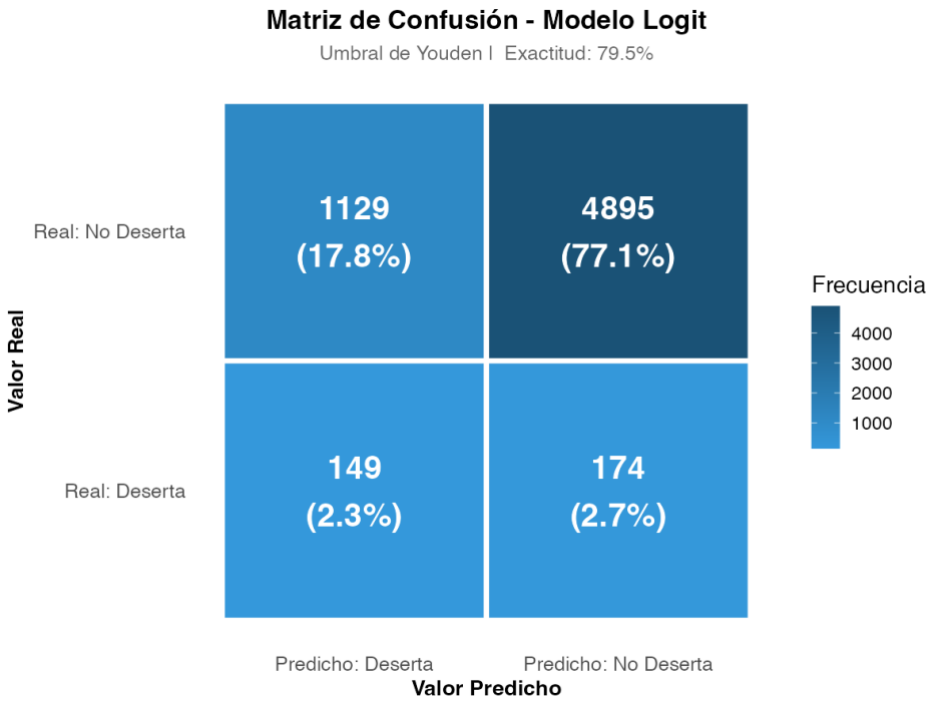

VP = Verdaderos Positivos (desertores detectados). VN = Verdaderos Negativos. FP = Falsos Positivos (alarmas falsas). FN = Falsos Negativos (desertores no detectados).

Con respecto a los resultados obtenidos en la matriz de confusión (gráfica 1), se puede interpretar lo siguiente:

Verdaderos Positivos (VP = 149, 2.3%): El modelo identifico correctamente 149 de los 323 desertores reales. Estos son los clientes que el equipo de Wall puede contactar proactivamente. Representan el 46.1% de todos los desertores (sensibilidad = 46.1%).

Verdaderos Negativos (VN = 4,895, 77.1%): 4,895 clientes fueron correctamente clasificados como no desertores. El modelo no genera esfuerzo innecesario del equipo de retención para estos clientes.

Falsos Positivos (FP = 1,129, 17.8%): 1,129 clientes fueron clasificados como en riesgo pero no desertaron. Son alarmas falsas, el equipo los contactaría sin necesidad. Con el umbral de Youden, se acepta este costo para maximizar la detección de desertores reales.

Falsos Negativos (FN = 174, 2.7%): 174 desertores reales NO fueron detectados por el modelo. Son el principal punto débil: clientes que abandonaran la empresa sin que el equipo haya intervenido. Reducir los FN es la prioridad de mejora del modelo. Con McFadden $R^2 = 0.044$ (ajuste modesto), es esperable que una proporción significativa de desertores no sean capturados.

Gráfica 2. Gráfica de Errores Modelo Logit

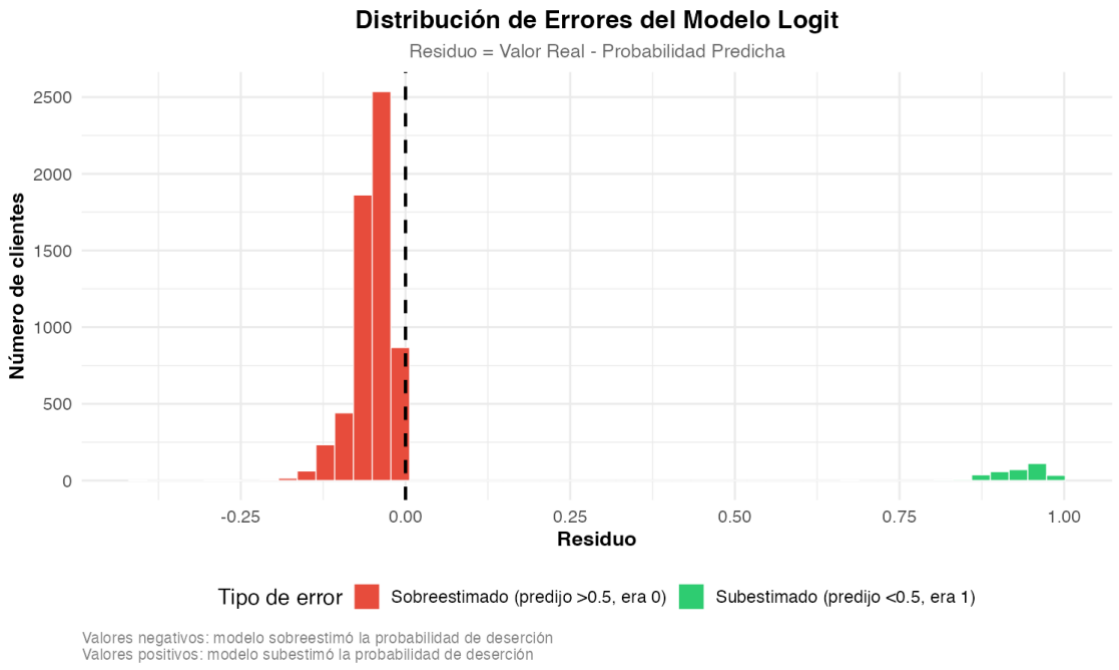

El gráfico de errores muestra los residuos, que se calculan como el valor real menos la probabilidad predicha. Como la variable dependiente es binaria, los residuos terminan agrupados en dos zonas bien separadas, lo cual tiene sentido.

La parte roja, entre –0.25 y 0, corresponde a los clientes que no abandonaron (valor real = 0) y a quienes el modelo asignó una probabilidad pequeña pero no nula. Estos errores son chicos, lo que en principio es buena señal porque esto significa que el modelo no está sobreestimando masivamente la probabilidad de deserción de los clientes que se quedan.

La gran mayoría de observaciones cae en este grupo porque la mayoría de clientes no desertó.

El problema está en la parte verde de la derecha, entre 0.85 y 1.0. Estos son los clientes que sí desertaron (valor real = 1) pero a los que el modelo les estimó una probabilidad muy baja, generando un residuo cercano a 1. Aunque numéricamente son pocos (aproximadamente 300 casos contra miles en el otro extremo), representan los falsos negativos del modelo: clientes que efectivamente se fueron y que el modelo no logró identificar como riesgosos. Para el objetivo del negocio este es justamente el tipo de error más costoso, porque son clientes que QWE no alcanzó a contactar a tiempo.

Otro detalle interesante es que entre 0 y 0.85 prácticamente no hay observaciones. Esto ocurre porque, como vimos en el gráfico anterior, las probabilidades predichas casi nunca son intermedias o altas: o son muy bajas (residuo cercano a 0) o, cuando el cliente desertó y el modelo no lo predijo, el residuo se va casi a 1.

Gráfica 3. Probabilidades Predichas vs Valores Reales

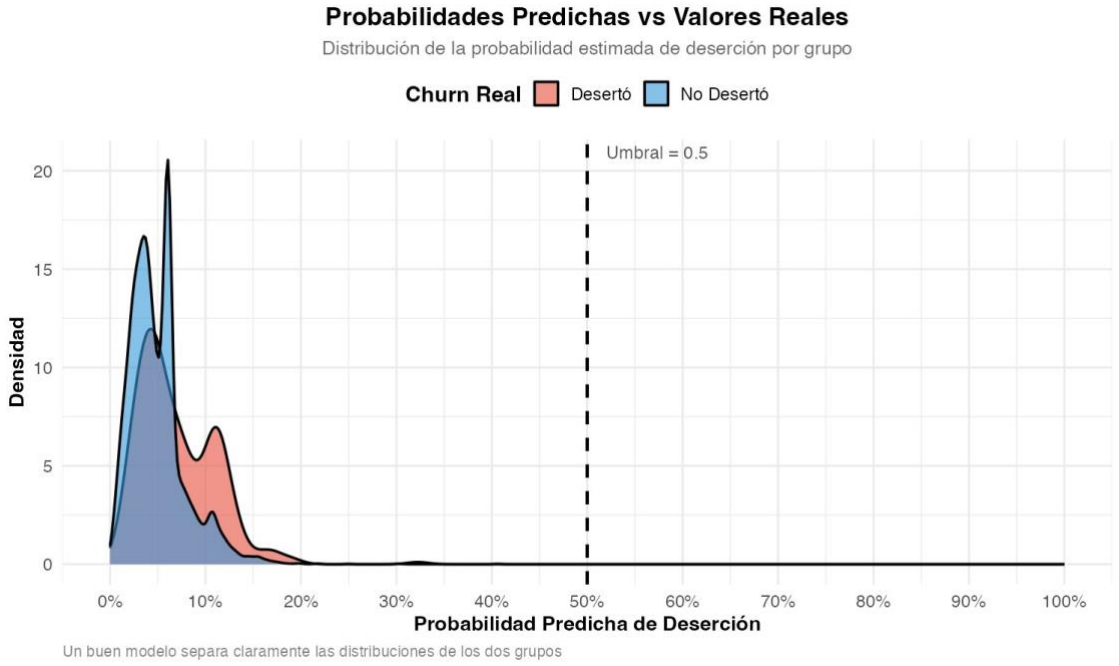

Lo primero que se ve en este gráfico es que las dos distribuciones están concentradas a la izquierda, casi todas por debajo del 20% de probabilidad estimada. Esto tiene sentido porque en el caso solo una pequeña parte de los clientes se va, entonces el modelo aprende que lo normal es que no haya deserción. Por eso, casi ningún cliente tiene una probabilidad alta, y ninguno llega a 0.5. Esto muestra que usar ese punto como regla para clasificar no sirve en este caso, porque terminaríamos diciendo que nadie se va. Por eso en el código se buscó un punto de corte más bajo, que se ajuste mejor a este tipo de datos.

Aun así, la gráfica sí muestra que el modelo está haciendo algo bien. Los clientes que sí desertan tienden a tener probabilidades un poco más altas que los que no, lo que indica que variables como el uso de la plataforma, el CHI o los problemas de soporte sí ayudan

a identificar riesgo. Es decir, el modelo logra captar ciertas señales que explican por qué algunos clientes terminan yéndose.

Sin embargo, también hay una parte donde ambos grupos se mezclan bastante, especialmente entre probabilidades de 3% a 10%. En ese rango es difícil distinguir quién se va y quién no, lo que muestra que el modelo no es perfecto para clasificar cliente por cliente. Aun así, sigue siendo útil para ordenar a los clientes según su nivel de riesgo. Y eso es clave en este caso, porque la idea no es acertar todo, sino identificar a los clientes más riesgosos para actuar a tiempo.

Flujo de Trabajo con IA – Marco de las 4D

D1 Delegación: ¿Qué le pedimos a la IA y que decidimos nosotros?

Como grupo definimos tres preguntas antes de empezar a utilizar la IA: ¿Qué variables predicen de forma significativa la deserción de clientes? ¿Cuál es el efecto del CHI Score sobre el riesgo? ¿Cómo evaluar correctamente el modelo teniendo en cuenta el desbalance del 5%? Todas estas preguntas nos surgieron después de leer el caso.

La IA que decidimos utilizar fue Claude la cual nos dio un código base para la creación de los modelos y cálculos necesarios. Además, nos ayudo a que los gráficos quedaran más completos con los ejes en las escalas y títulos adecuados; sin embargo, nuestro trabajo se centró en la correcta selección de las variables, la selección del modelo Logit, la interpretación de los resultados, las conclusiones y recomendaciones.

D2 Descripción: ¿Cómo le explicamos lo que queríamos?

Prompt 1: Creación del modelo_logit con umbral de Youden

"Tengo un data frame en R llamado "datos" con estas columnas: churn (binaria 0/1, edad_cliente, chi_mes0, chi_cambio, casos_soporte_mes0, casos_soporte_cambio, logins_cambio, views_cambio, dias_sin_login_cambio. Estima un modelo logit con glm() usando todas las variables. Dado que solo el ~5% deserto, calcula el umbral optimo usando el índice de Youden. Incluye la matriz de confusión con caret."

Este prompt no funciono del todo. Ya que este construía el subtitulo del grafico de la matriz de confusión de forma fija que decía "Umbral de clasificación 0.5" lo cual resulta incorrecto ya que en el modelo se utilizó el umbral de Youden. Se realizo la corrección especificando que el subtítulo se debía generar usando paste0(), lo que se corrigió en el script final.

Prompt 2: Exportación de las tablas a Word con flextable

"Con el modelo logit estimado y el data frame tabla_coef (columnas: Variable, coeficiente, Error_Std, Estadistico_Z, p_value, Significancia), genera un código flextable y officer para exportar la tabla descriptiva y la de regresión a un archivo de Word. Incluye los encabezados y en una nota al pie con el R^2 McFadden y el N"

Este prompt funciono de forma parcial ya que inicialmente nombro una columna z_value lo cual no coincidía con el nombre propuesto por nosotros "Estadistico_Z"

dentro del data frame. Lo que se corrigió especificando de forma clara los nombres de las columnas.

D3 Discernimiento: ¿El output que genero la IA estaba bien?

Revisamos de forma cuidadosa el código que nos generó la IA e identificamos distintas situaciones. Primero el subtítulo de la matriz de confusión estaba incorrecto por lo que se le indico a la IA que se debía construir utilizando la función paste0() usando el umbral Youden calculado. Segundo el nombre de una de las columnas de la tabla de coeficientes no era consistente con lo especificado en el data frame, esto se corrigió especificando los nombres exactos de las columnas en el prompt 2. Finalmente se verificaron los signos de los coeficientes que la IA genero de forma correcta ya que los signos correspondían a la lógica de los datos y el negocio.

D4 diligencia: ¿Podemos responder por lo que entregamos?

Los resultados de los que estamos más seguros son de los tres factores clave como el cambio en CHI Score ($p>0.001$), días sin login ($p<0.001$) y cambio en casos de soporte ($p<0.05$). Estos resultados son sólidos, coherentes con la teoría y con la intuición de Wall, y se verificaron de forma directa con los resultados arrojados de R con summary(modelo_logit), tienen sentido teniendo en cuenta la teoría de retención de clientes, entendemos los resultados y podríamos defenderlos sin necesidad del script .

El resultado que nos generó más dudas fue la sensibilidad del modelo (46.1% por lo que únicamente detecta 149 de 323 desertores). Con un R^2 McFadden = 0.044, se espera que muchos de los desertores no sean capturados. Por lo que como grupo no podemos garantizar que la lista de los 100 clientes en riesgo los incluya a todos los que realmente van a desertar.

La IA (Claude) nos ayudó con la base del código, embellecimiento de los gráficos y la estructura del documento en Word. Nosotros definimos las preguntas a analizar, seleccionamos las variables, decidimos las que se excluirían en el código, interpretamos los coeficientes y formulamos las recomendaciones.

Conclusiones y Recomendaciones

Los resultados del modelo nos permiten concluir que el CHI Score se consolida como el predictor más importante de la deserción de clientes. Tanto su nivel inicial como su variación mensual presentan una relación negativa y altamente significativa con el churn, lo que confirma que una caída pronunciada en este indicador de satisfacción es una señal temprana critica de abandono. Diciéndolo de otra forma, los clientes cuyo nivel de satisfacción disminuye de forma acelerada en un corto periodo tienen una mayor propensión a cancelar el servicio en los siguientes meses, lo que resulta validando la intuición inicial del equipo de Wall y posicionando esta medida como eje central para cualquier estrategia de retención.
En segundo lugar, la inactividad del cliente resulta ser la señal operativa más clara luego del CHI Score anteriormente mencionado. El aumento de los días sin acceso a la plataforma aumenta de forma importante la probabilidad de deserción, lo cual refleja que la falta de uso está directamente asociada a una pérdida de valor percibido. A diferencia del CHI Score, esta variable se puede observar en tiempo real lo que la

convierte en una herramienta practica y accionable para la gestión diaria del cliente. A esto se suma que la acumulación de tickets de soporte también influye significativamente el riesgo de churn, lo que evidencia que los problemas técnicos no resueltos deterioran la experiencia del usuario y aumentan la probabilidad de abandono.

Aunque el modelo presenta un nivel de ajuste global modesto, este es consistente con la naturaleza del fenómeno analizado, en el que la deserción es un evento poco frecuente. Sin embargo, su capacidad predictiva resulta útil para el propósito especifico de la empresa, ya que permite identificar una proporción relevante de clientes en riesgo y priorizar las acciones sobre ellos. Aunque, es importante ser conscientes de que una parte considerable de desertores no es capturada por el modelo. En este sentido, la exclusión de algunas variables responde a una decisión metodológica orientada a un modelo simple.

Teniendo en cuenta los hallazgos, se le recomienda a la empresa implementar de forma periódica el modelo ya que es una herramienta operativa importante para el proceso de retención, generando listas mensuales de clientes en alto riesgo para intervenir de forma anticipada. Asimismo, se deben establecer sistemas de alerta temprana, especialmente ante caídas significativas en el CHI Score, porque este resulta ser el indicador más contundente de abandono inminente. También se debe monitorear de forma constante la inactividad para que se activen estrategias de reactivación antes de que el cliente se desvincule por completo.

En paralelo, es fundamental fortalecer la gestión de soporte técnico, priorizando la resolución efectiva en el primer contacto y reduciendo la incidencia de problemas ya que esto impacta en la retención. Finalmente el modelo se podría mejorar si se incorporaran más periodos de análisis y nuevas variables que capturen mejor los comportamientos del cliente, lo que mejoraría precisión y reducción de casos no detectados.